实验五： Spark SQL 编程实践

实验基本信息：

时间： ： 2024 年 9 月 30 日

实验类型： □验证性 □设计性 ☑综合性

班级： 计算机科学与技术专业（中外合作）4 班 班级代码:
理论老师： 邱开金 实验指导： 邱开金

实验报告提交说明：

本次实验需要撰写实验报告，实验报告填写时以完成实验任务为目的，先简要回答完成实验任务需要的步骤或需要执行的命令代码，再配以结果截图予以说明，图片数量不宜过多，能说明问题即可。最后配上总结，并提交到教师指定位置。

实验目的：

1. 了解 SparkSession 创建 DataFrame。
2. 了解从 RDD 转化为 DataFrame 的方法。
3. 熟练使用 DataFrame 提供的算子完成具体任务。
4. 熟练使用 spark.sql 执行 SQL 语句，完成具体任务。

实验任务：

1. 安装 mysql 和 HBase. 把安装的截图放上来。

MySQL:

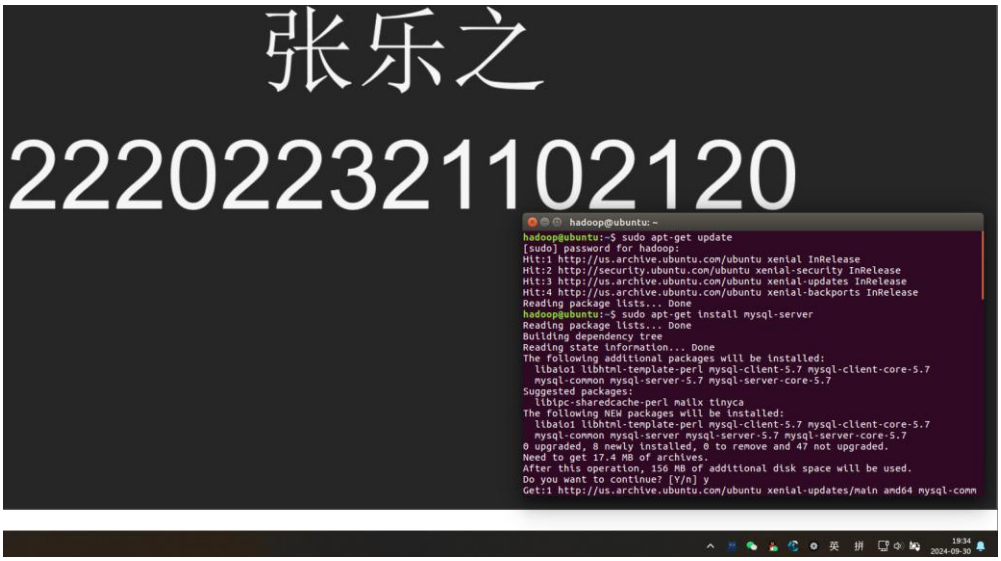

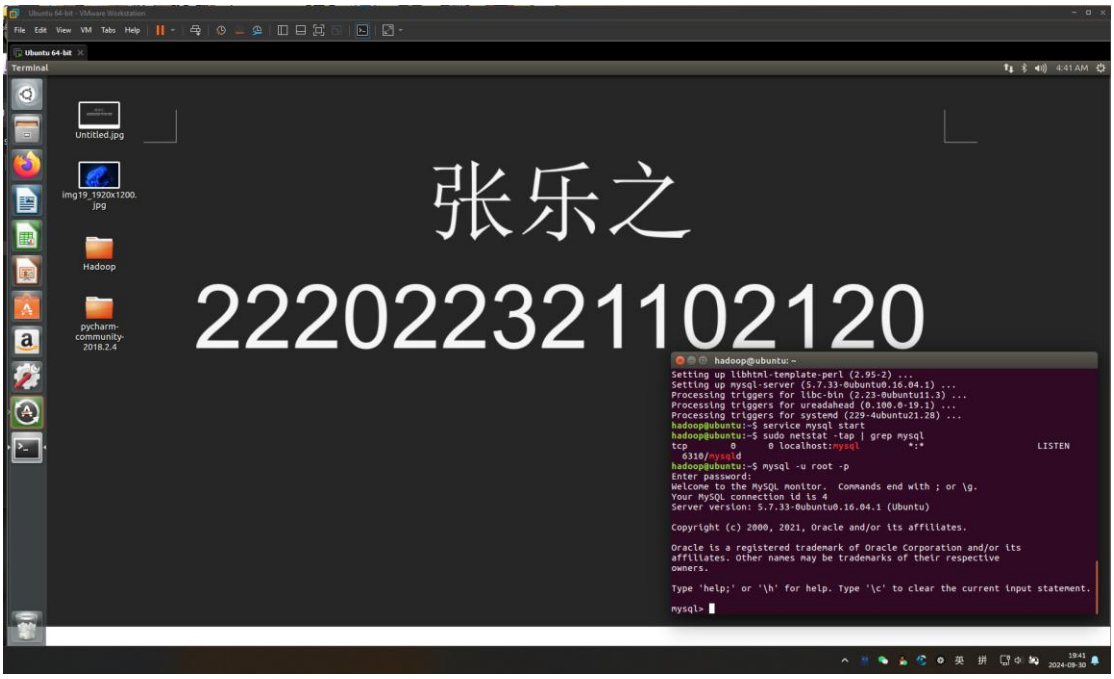

安装 hbase：

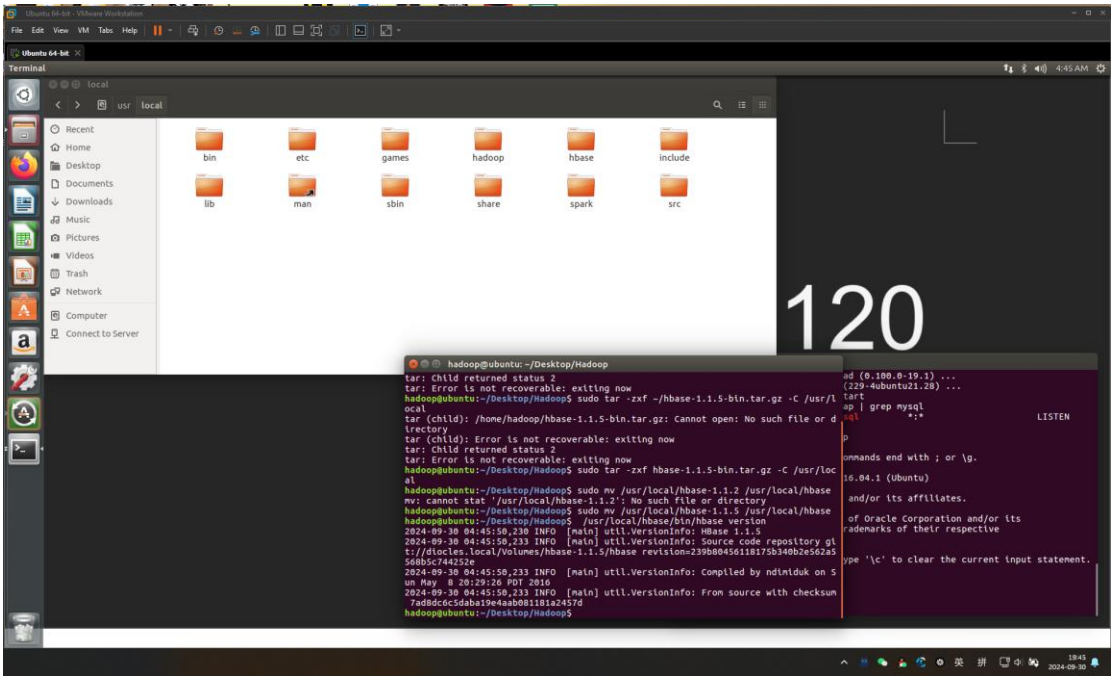

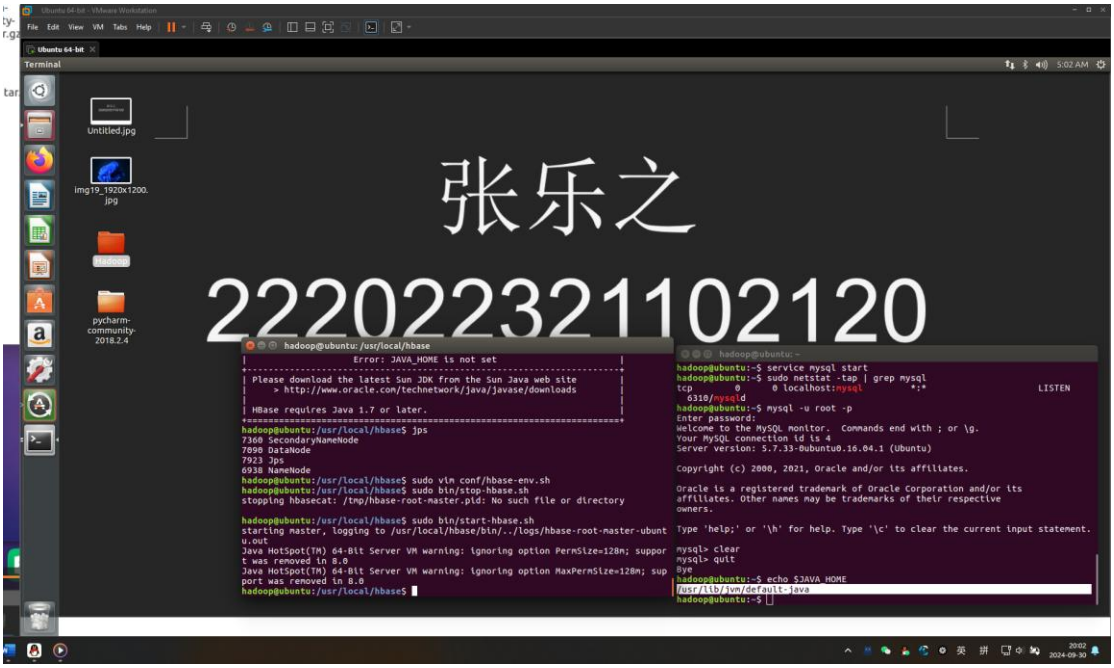

2. 读取文件 people.json,转换为 DataFrame，完成以下实验任务

1. 文件位于： usr/local/spark/examples/src/main/resources/people.json

1）统计文件中记录总数。

2）查询年龄小于 20 岁的记录。

3）根据当前年份及年龄计算出生日期。

```
from pyspark.sql import SparkSession

spark = SparkSession.builder.appName("People Analysis").getOrCreate()

df = spark.read.json("file:///usr/lodcal/spark/examples/src/main/resources/people.json")

df.createOrReplaceTempView("people")

total_count = df.count()
print("Total record count: {}".format(total_count))

under_20 = df.filter(df.age < 20)
under_20.show()

from pyspark.sql.functions import expr

df_with_birthdate = df.withColumn("birth_year", expr("2024 - age"))
df_with_birthdate.show()
```

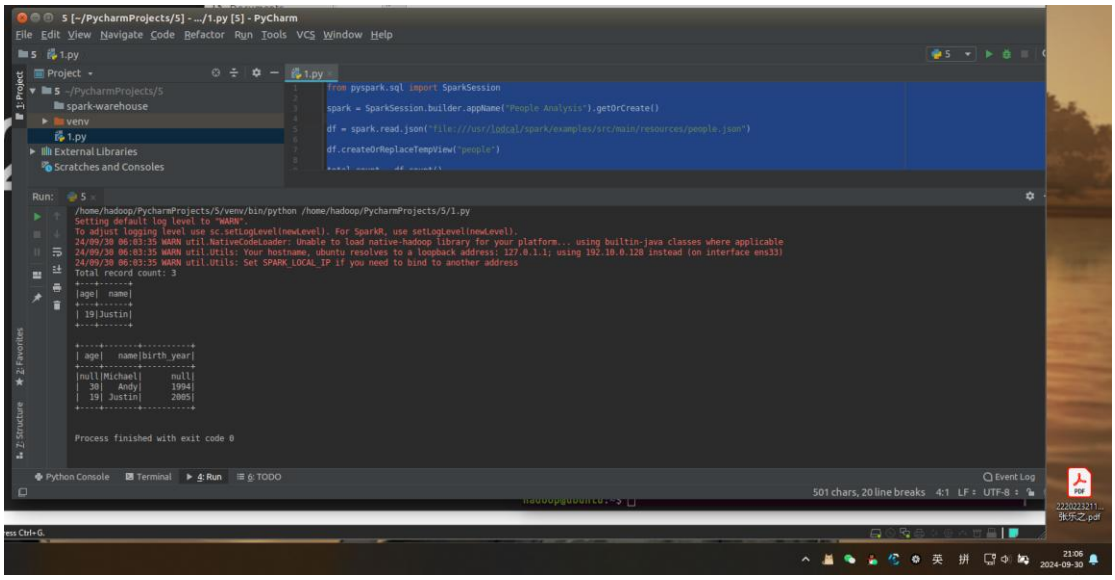

4）利用 SQL 语句重新完成 1）-3)的任务。

```
total_count_sql = spark.sql("SELECT COUNT(*) FROM people")
total_count_sql.show()

under_20_sql = spark.sql("SELECT * FROM people WHERE age < 20")
under_20_sql.show()


birthdate_sql = spark.sql("SELECT *, (2024 - age) AS birth_year FROM people")
birthdate_sql.show()
```

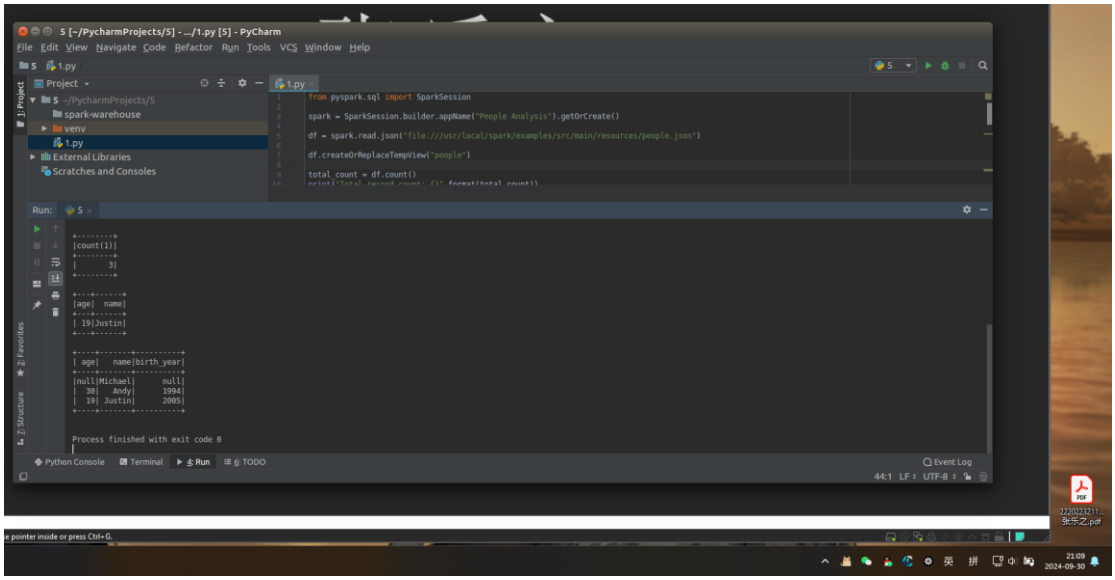

2. 读取 iris.txt 并转换成 DataFrame,完成计算任务

1) iris.txt 与实验四内容一致。读入 iris.txt 到 RDD 中，显示文件行数。

```
from pyspark.sql import SparkSession

from pyspark.sql import Row

spark = SparkSession.builder.appName("Iris Analysis").getOrCreate()


rdd = spark.sparkContext.textFile("file:///home/hadoop/Desktop/Hadoop/iris.txt")


line_count = rdd.count()

print("Total number of lines: {}".format(line_count))
```

2）利用任意一个种方法将 RDD 转换为 DataFrame，其中涉及的模式为 SepalLength,SepalWidth,PetalLength,PetalWidth,TrainingClass 。

```
columns = ["SepalLength", "SepalWidth", "PetalLength", "PetalWidth", "TrainingClass"]


row_rdd = rdd.map(lambda line: line.split(",")).map(lambda p: Row(SepalLength=float(p[0]),

SepalWidth=float(p[1]),

PetalLength=float(p[2]),

PetalWidth=float(p[3]),

TrainingClass=p[4]))


iris_df = spark.createDataFrame(row_rdd, schema=columns)

iris_df.show()
```

3）转换得到 DataFrame 后，利用 xx.createOrReplaceTempView("iris_view") 代码创建 iris_view。

```
iris_df.createOrReplaceTempView("iris_view")
```

4）利用 spark.sql 执行 SQL 语句完成如下任务：

a.统计总行数;

b.统计每种花的数量;

c.统计 PetalWidth 小于 2 的记录有哪些。

d.计算 Iris-virginica 花的平均 PetalLength 值，并输出。

```
total_count_sql = spark.sql("SELECT COUNT(*) FROM iris_view")
```

```
total_count_sql.show()

flower_count_sql = spark.sql("SELECT TrainingClass, COUNT(*) AS count FROM iris_view GROUP BY TrainingClass")
flower_count_sql.show()

petalwidth_filter_sql = spark.sql("SELECT * FROM iris_view WHERE PetalWidth < 2")
petalwidth_filter_sql.show()

avg_petal_length_sql = spark.sql("SELECT AVG(PetalLength) AS avg_petal_length FROM iris_view WHERE TrainingClass = 'Iris-virginica'")
avg_petal_length_sql.show()
```

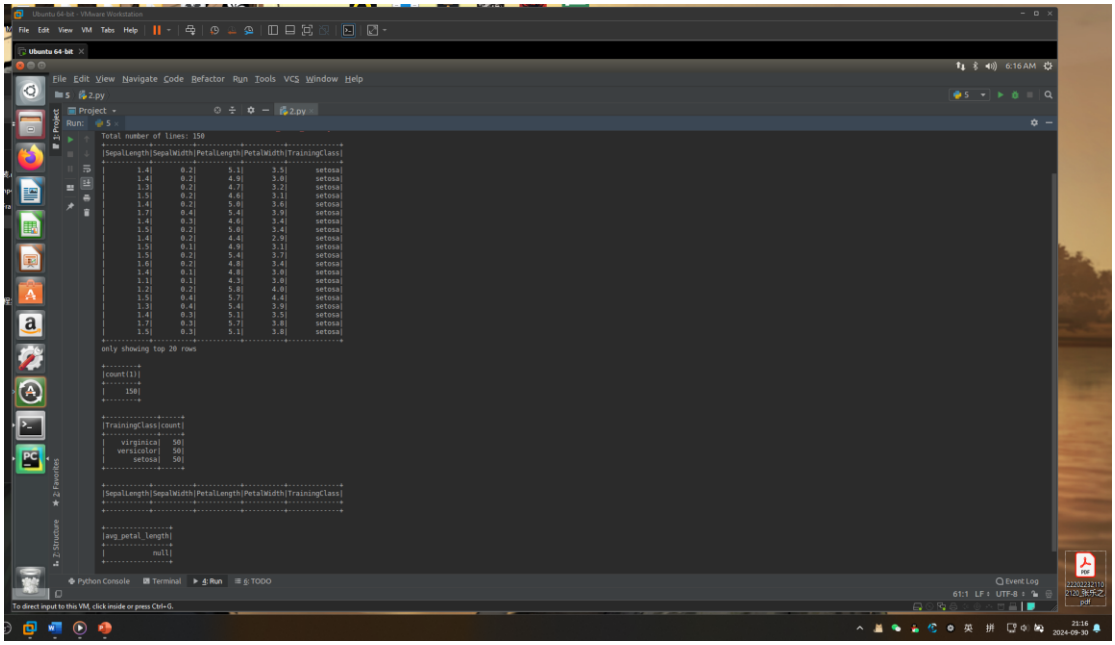

实验总结：

在本次实验中，我主要学习了 **SparkSQL** 技术来处理并分析数据。基于 Mysql 和 hbase 平台，并使用了 RDD 和 DataFrame 数据结构，我们编写了 python 程序来处理问题。首先将文本文件读取为 RDD，(Spark 中用于并行处理数据的底层结构)。然后通过 map 操作将 RDD 转换为 Row 格式，再使用 createDataFrame 将其转为 DataFrame，这样我们可以像操作数据库表一样对数据进行结构化查询。接着通过 createOrReplaceTempView 创建 SQL 视图，并利用 Spark SQL 进行总行数统计、分组统计、条件过滤等操作。Spark 的分布式计算模型和内存优化使其非常高效，适合大规模数据处理。